



UNIVERSITÄT
LEIPZIG

Medizinische Fakultät

MI-Lab Übung 5

Analysen medizinischer Datensätze mit tranSMART

Leipzig, Datum

imise.

ZIEL DER ÜBUNG

- Praktische Erfahrung mit Inhalten und Werkzeugen für die Durchführung einzelner Analysen
- Aufeinander aufbauende Abfragen mit steigendem Schwierigkeitsgrad auf einen medizinischen Datensatz
- Analysen anhand natürlichsprachlicher Fragestellungen formulieren

Szenario: MIMIC (Medical Information Mart for Intensive Care)

- Anonymisierte elektronische Krankenakten von Patienten, die in das Beth Israel Deaconess Medical Center aufgenommen wurden
- Öffentlich zugängliche Demo von MIMIC-IV mit 100 Patienten
- Online Dokumentation: <https://mimic.mit.edu>
- In der Übung wird eine komprimierte Version des Datensatzes verwendet

TranSMART

- Open source Data Warehouse
- Speicherung von großen Mengen klinischer Daten aus klinischen Studien sowie Daten aus der Grundlagenforschung
- Gemeinsame Abfrage für die translationale Forschung

Links: Navigationsbaum für klinische Konzepte

Ordner →

Kategorial →

Metrisch →

The screenshot displays a web-based interface for navigating clinical concepts. The left sidebar, titled 'Navigate Terms', contains a hierarchical tree of concepts. The main workspace on the right features two panels, 'Subset 1' and 'Subset 2', each with 'Include', 'Exclude', and 'Clear Panel' buttons, and a dashed box for dragging concepts. The top navigation bar includes tabs like 'Comparison', 'Summary Statistics', 'Grid View', 'Advanced Workflow', 'SmartR', 'Data Export', 'Export Jobs', 'Workspace', and 'Genome Browser'. The bottom right corner shows the logo of the Universitätsmedizin Göttingen, Department of Medical Informatics, and a database icon.

Auswahl der gesamten Studie

The screenshot shows the UMG data analysis interface. On the left, a 'Navigate Terms' sidebar lists various medical concepts. 'Hyperlipidämie' is selected and circled in red. A red arrow points from this selection to the 'Include' button in the 'Subset 1' panel. The 'Subset 1' panel also has 'abc E78.5' entered. The 'Subset 2' panel is empty. The interface includes tabs for 'Compare', 'Summary Statistics', 'Grid View', 'Advanced Workflow', 'SmartR', 'Data Export', 'Export Jobs', 'Workspace', and 'Genome Browser'.

- Die gewählte Kohorte umfasst alle Probanden mit der Diagnose Hyperlipidämie
- Weitere Konzepte können in das gleiche Fenster (ODER-Verknüpfung) in das darunter (UND-Verknüpfung) oder das daneben (2. Kohorte für Vergleiche) geschoben werden

Gewünschte Analysefunktion auswählen

The screenshot displays the Transmart dataset explorer interface. On the left, a 'Navigate Terms' tree shows a hierarchy of data categories: Across Trials, Public Studies, Breast Cancer_Desmedt_GSE7390 (19), MIMIC (100), Admissions (100), admission type (100), Insurance (100), Clinical Data (100), Diagnosis (100), Lab Values (100), Medication (100), Ventilation (100), Vital Parameters (100), Subjects (100), Demographics (100), Medical History (61), and weight (61). The 'Advanced Workflow' menu is open, listing various analysis functions. A red circle highlights the 'Advanced Workflow' menu item in the top navigation bar. A red arrow points from this circle to the 'Survival Analysis' option in the dropdown menu, which is also highlighted with a red rectangle. The 'Survival Analysis' option is the selected function.

Active Filters: **Filter** **Clear**

Navigate Terms

- Across Trials
- Public Studies
- Breast Cancer_Desmedt_GSE7390 (19)
- MIMIC (100)
 - Admissions (100)
 - admission type (100)
 - Insurance (100)
 - Clinical Data (100)
 - Diagnosis (100)
 - Lab Values (100)
 - Medication (100)
 - Ventilation (100)
 - Vital Parameters (100)
 - Subjects (100)
 - Demographics (100)
 - Medical History (61)
 - weight (61)

Analysis

- aCGH Survival Analysis
- Box Plot with ANOVA
- Correlation Analysis
- Frequency Plot for aCGH
- Group Test for aCGH
- Group Test for RNASeq
- Heatmap
- Hierarchical Clustering
- IC50
- K-Means Clustering
- Line Graph
- Logistic Regression
- Marker Selection
- PCA
- Scatter Plot with Linear Regression
- Survival Analysis**
- Table with Fisher Test
- Waterfall

localhost/transmart/datasetExplorer#


Aufgaben

- 1. Überblick der Studie**
- 2. Vergleich von Subsets**
 - Patienten mit Diagnosen Hyperlipidämie und Vorhofflimmern
- 1. Boxplot**
 - Laborwert Hämatokrit
- 1. Korrelationsanalyse**
 - Korrelation zwischen Alter und Gewicht
- 1. Überlebenszeitanalyse**
 - Vergleich von zwei Kurven

Lösung 2: Vergleich von Subsets


- Subset 1:
 - **34** Patienten mit Diagnose Hyperlipidämie
- Subset 2:
 - **18** Patienten mit Diagnose Vorhofflimmern
- **11** Patienten mit beiden Diagnosen

→ Das durchschn. Alter beider Subsets ist fast gleich




Lösung 3: Boxplot

- Laborwert: **Hematocrit**
 - Subset 1: Pat mit Hyperlipidämie
 - Subset 2: Pat mit Vorhofflimmern
- Patienten mit **Vorhofflimmern** haben durchschn. einen **höheren** Hämatokritwert



Lösung 4: Korrelationsanalyse

- Subset: Patienten mit Vorhofflimmern
 - Korrelation:
 - Alter und Gewicht
- Korrelationskoeffizient = **-0,5**
- Je **älter** die Patienten sind, desto **weniger** wiegen sie



Lösung 5: Überlebenszeitanalyse


- Vergleich Überlebenszeit zwischen:
 - Patienten mit Hyperlipidämie
 - Patienten mit Vorhofflimmern
- Kaplan-Meier-Kurve
- Variablen:
 - Time: Age
 - Censoring Variable: Alive

Lösung 5: Überlebenszeitanalyse

Survival Curve

Hyperlipidämie


Kaplan-Meier estimator



Survival Curve

Vorhofflimmern

Kaplan-Meier estimator



beide 80 Jahre



UNIVERSITÄT
LEIPZIG

Medizinische Fakultät

VIELEN DANK!

Mona Perbix

Institut für Medizinische Informatik, Statistik und Epidemiologie (IMISE)